

ការប៉ាន់ស្មាន (Estimation)

១ សេចក្តីផ្តើម

- ឧបមាថាយើងមានសំនុំសាកល (population) ដែលមានទំហំ N មធ្យម μ និង រ៉ាង្ស៊ីង σ^2 ។ μ និង σ^2 ត្រូវបានគេហៅថាប៉ារ៉ាម៉ែត្រ (parameter) ។
- ចេញពីសំនុំសាកលនេះ យើងរើសគំរូតាង (sample) ដោយចៃដន្យដែលមានទំហំ n ជាមួយ $n \leq N$ ។ តាមរយៈគំរូតាងដែលយើងរើសបាន យើងអាចគណនា មធ្យម \bar{X}_n និង រ៉ាង្ស៊ីង S_n^2 ។ \bar{X}_n និង S_n^2 ត្រូវបានគេហៅថា statistics ។
- វត្ថុបំណងនៃមេរៀននេះគឺ យើងប្រើ statistics (\bar{X}_n, S_n^2) ដើម្បីប៉ាន់ស្មាន parameter (μ, σ^2) ។ ក្នុងការប៉ាន់ស្មាននេះ យើងនឹងប្រើវិធី Maximum Likelihood Estimation (MLE) ។
- ជាធម្មតា គំរូតាងមួយបង្កើតបាន statistics មួយ (ចេញពីសំនុំសាកល (population) ដែលមានទំហំ N យើងអាចរើសបានគំរូតាង (sample) ដោយចៃដន្យដែលមានទំហំ n ច្រើនអនេក)។ ដោយសារតែយើងមានគំរូតាងច្រើន នោះ statistics ក៏មានតម្លៃច្រើនដែរ ដែលជាទូទៅតម្លៃនីមួយៗមិនស្មើគ្នាទេ។ ចុះបើ statistics (\bar{X}_n) មានតម្លៃច្រើនបែបនេះ តើយើងគួរប្រើតម្លៃមួយណាដើម្បីប៉ាន់ស្មាន parameter (μ) ?
- ក្នុងជាក់ស្តែង យើងមានលទ្ធភាពរើសយកគំរូតាងតែមួយទេ (រើសច្រើនដង ចំណាយច្រើន)។

២ ការប៉ាន់ស្មានជាចំនុច (Point Estimation)

២.១ ម៉ូដែលស្ថិតិ (statistical model)

នៅជំពូកមុនយើងបានសិក្សាពីអថេរចៃដន្យ លក្ខណៈនានារបស់វា និង អថេរចៃដន្យមួយចំនួន។ ជាធម្មតាអថេរចៃដន្យត្រូវបានកំណត់លក្ខណៈ (សំគាល់) ដោយអនុគមន៍ដង់ស៊ីតេ ដែលជាធម្មតាអនុគមន៍ដង់ស៊ីតេអាស្រ័យទៅនឹងប៉ារ៉ាម៉ែត្រ θ ។ បើ $\theta \in \mathbb{R}^k$ នោះយើងសិក្សានៅក្នុងស្ថិតិប៉ារ៉ាម៉ែត្រ (Parametric Statistics) ហើយបើ $\theta \notin \mathbb{R}^k$ នោះយើងសិក្សានៅក្នុងស្ថិតិមិនប៉ារ៉ាម៉ែត្រ (Nonparametric Statistics)។ ក្នុងវគ្គនេះយើងនឹងសិក្សាតែក្នុងករណី ដែល $\theta \in \mathbb{R}^k$ ។ វត្ថុបំណងក្នុងចំណុចនេះ គឺការប៉ាន់ស្មាន θ ដោយប្រើប្រាស់សំនុំទិន្នន័យ x_1, x_2, \dots, x_n ។

ឧទាហរណ៍ ១. ឧបមាថាយើងបោះកាក់មួយ n ដង ដែលក្នុងការបោះមួយដងៗឱកាសនៃការចេញមុខគឺ $p, 0 < p < 1$ ។ តាង X ជាចំនួនមុខដែលផ្ទៀងផ្ទាត់។ នោះគេថា X ជាអថេរចៃដន្យមានបំណែងចែកឡែនដែលអនុគមន៍ដង់ស៊ីតេអោយដោយរូបមន្ត៖

$$P_p(X = k) = C_n^k p^k (1-p)^{(n-k)}, \quad k = 0, 1, 2, \dots, n$$

តាមរូបមន្តនេះយើងឃើញថា អនុគមន៍ដង់ស៊ីតេអាស្រ័យទៅនឹង p ដែល p ហៅថាប៉ារ៉ាម៉ែត្រ។

និយមន័យ ១. ម៉ូដែលស្ថិតិ (Statistical Model) គឺជាគ្រួសារនៃអនុគមន៍ដង់ស៊ីតេ $\{P_\theta, \theta \in \Theta \subset \mathbb{R}^k\}$ ដែល P_θ ជាអនុគមន៍ដង់ស៊ីតេរបស់អថេរចៃដន្យណាមួយ។

ឧទាហរណ៍ ២. ឧទាហរណ៍នៃម៉ូដែលស្ថិតិ

- បំណែងចែកប៊ែរណូលី (Bernoulli Distribution):

$$\{P_\theta, \theta \in \Theta \subset \mathbb{R}^k\} = \{p^x(1-p)^{1-x}, p \in]0, 1[\}$$

- បំណែងចែកក្រូឌា (Binomial Distribution):

$$\{P_\theta, \theta \in \Theta \subset \mathbb{R}^k\} = \{C_n^x p^x (1-p)^{(n-x)}, p \in]0, 1[\}$$

- បំណែងចែកព័រស្កង់ (Poisson Distribution):

$$\{P_\theta, \theta \in \Theta \subset \mathbb{R}^k\} = \left\{ \frac{e^{-\lambda} \lambda^x}{x!}, \lambda \in]0, \infty[\right\}$$

- បំណែងចែកន័រម៉ាល់ (Normal Distribution):

$$\{P_\theta, \theta \in \Theta \subset \mathbb{R}^k\} = \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, (\mu, \sigma^2) \in \mathbb{R} \times]0, \infty[, k=2 \right\}$$

២.២ អនុគមន៍ likelihood (Likelihood Function)

ក្នុងចំណុចនេះយើងនឹងសិក្សាអំពីការគណនាការប៉ាន់ស្មានជាចំណុច (point estimator) តាមរយៈអនុគមន៍ likelihood។

និយមន័យ ២. X ជាអថេរចៃដន្យដែលមានអនុគមន៍ដង់ស៊ីតេ $f_\theta(x)$ រឺ $P_\theta(X=x)$ នោះអនុគមន៍ likelihood ត្រូវបានគេអោយនិយមន័យដោយ

$$L_x(\theta) = \prod_{i=1}^n f_\theta(x_i), \theta \in \Theta$$

ហើយ អនុគមន៍ log-likelihood ត្រូវបានគេអោយនិយមន័យដោយ

$$l_x(\theta) = \ln(L_x(\theta)), \theta \in \Theta$$

សម្គាល់ ១. • f_θ ជាអនុគមន៍នៃ x ហើយ L_x និង l_x ជាអនុគមន៍នៃ θ ។

- ដោយលោការីតជាអនុវត្តន៍មួយទល់មួយ ដូចនេះដើម្បីសិក្សាពីការប៉ាន់ស្មាន យើងប្រើ $L(\theta)$ និង $l(\theta)$ អោយលទ្ធផលដូចគ្នា។
- *i.i.d = Independent and identically distributed random variables*

ឧទាហរណ៍ ៣. មាន $X_i \sim i.i.d \text{ Ber}(p), 0 < p < 1$ ដែល $i = 1, 2, \dots, n$ ។ ចូរកំណត់ $L(p)$ និង $l(p)$ ។

ចំណុចបន្ទាប់ យើងនឹងសិក្សាពីការប៉ាន់ស្មាន θ ដោយប្រើប្រាស់សំនុំទិន្នន័យ x_1, x_2, \dots, x_n ។ តំលៃប៉ាន់ស្មាននៃប៉ារ៉ាម៉ែត្រ θ (estimator) គឺជាតំលៃ (statistic) ទាំងឡាយណាដែលធ្វើអោយ l មានតំលៃអតិបរមា។

និយមន័យ ៣. យើងថា $\hat{\theta}$ ជាតំលៃប៉ាន់ស្មាននៃប៉ារ៉ាម៉ែត្រ θ (estimator) បើ

$$\hat{\theta} = \text{Argmax}_{\theta \in \Theta} l(\theta)$$

ឧទាហរណ៍ ៤. ចូរកំណត់តំលៃប៉ាន់ស្មាននៃប៉ារ៉ាម៉ែត្រ θ (estimator) ក្នុងករណី៖

- បំណែងចែក Bernoulli, Poisson, Geometric
- បំណែងចែក Uniform $[0, \theta]$, Exponential, Normal

ទ្រឹស្តីបទ ១. មាន X_i អថេរចៃដន្យ *i.i.d* និង ដង់ស៊ីតេ $f_\theta(x)$ ។ ឧបមាថាមានអនុគមន៍ g ដែល $\lambda = g(\theta)$ នោះតំលៃប៉ាន់ស្មានរបស់ λ គឺ $\hat{\lambda} = g(\hat{\theta})$ ដែល $\hat{\theta}$ ជាតំលៃប៉ាន់ស្មាននៃប៉ារ៉ាម៉ែត្រ θ ។

សម្រាយ

dfdsdgsdfgsdfhgdgfsfd □

ឧទាហរណ៍ ៥. ចូរគណនាតំលៃប៉ាន់ស្មានរបស់ $V(x)$ បើ $X \sim Ber(p)$ ។

សម្គាល់ ២. • ជាធម្មតាតំលៃប៉ាន់ស្មានរបស់ប៉ារ៉ាម៉ែត្រ គេតែងតែបែងចែកជា n , $\hat{\theta}_n$

- យើងឃើញថាតំលៃប៉ាន់ស្មាន $\hat{\theta}_n$ ជាអនុគមន៍នៃ X_1, X_2, \dots, X_n ដែលសុទ្ធតែជាអថេរចៃដន្យ នោះ $\hat{\theta}_n$ ក៏ជាអថេរចៃដន្យដែរ។

ការសន្មត ១. (Regular Condition)

- Identifiability: បើ $\theta \neq \theta'$ នោះ $f_\theta(x) \neq f_{\theta'}(x)$
- Support: គ្រប់អនុគមន៍ដង់ស៊ីតេមានទម្រង់ដូចគ្នា, $\forall \theta \in \Theta$

សម្គាល់ ៣. យើងក៏មានវិធីសាស្ត្រផ្សេងទៀតដើម្បីកំណត់តំលៃប៉ាន់ស្មាននៃប៉ារ៉ាម៉ែត្រ θ (estimator) គឺវិធីម៉ូម៉ង់ (Moment Method) ។ ឧបមាថាមានអថេរចៃដន្យ X ដែលមានម៉ូម៉ង់កំណត់ (finite k^{th} moment) មានន័យថា $E[|x^k|] < \infty$ នោះតំលៃប៉ាន់ស្មានរបស់ $\theta_k = E[x^k]$ អោយដោយរូបមន្ត

$$\hat{\theta}_{k,n} = \frac{1}{n} \sum_{i=1}^n X_i^k$$

ឧទាហរណ៍ ៦. ចូរគណនាតំលៃប៉ាន់ស្មានរបស់ $E(X)$ និង $V(x)$ តាមវិធី Likelihood និង ម៉ូម៉ង់ប៊េនៈ

- $X \sim Ber(p)$
- $X \sim N(\mu, \sigma^2)$

២.៣ លក្ខណៈនៃការប៉ាន់ស្មានជាចំនុច (Properties of Point Estimator)

បន្ទាប់ពីនិយាយពីតំលៃប៉ាន់ស្មានរួចហើយ ជាបន្ទាប់យើងនឹងនិយាយពីលក្ខណៈនានារបស់តំលៃប៉ាន់ស្មាននោះ។

និយមន័យ ៤. ១. (Unbiased) : យើងថា $\hat{\theta}_n$ ជាតំលៃប៉ាន់ស្មានមិនឆ្គង (unbiased estimator) របស់ θ បើ

$$E(\hat{\theta}_n) = \theta$$

២. (Efficiency): យើងថា $\hat{\theta}_n$ ជាតំលៃប៉ាន់ស្មានដែលមានប្រសិទ្ធភាព (efficient estimator) របស់ θ បើ

$$V(\hat{\theta}_n) \xrightarrow{n \rightarrow \infty} 0$$

៣. (Consistency): យើងថា $\hat{\theta}_n$ ជាតំលៃប៉ាន់ស្មានកុងស៊ីស្តង់ (consistent estimator) របស់ θ បើ $\hat{\theta}_n$ រួមរកប៉ារ៉ាម៉ែត្រ θ ក្នុងប្រូបាប ដែលគេកំណត់សរសេរដោយ

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{P} \theta$$

៤. [Mean Square Error (MSE)]: អោយដោយរូបមន្ត

$$MSE(\hat{\theta}_n) = E[(\hat{\theta}_n - \theta)^2] = V(\hat{\theta}_n) + (Bias(\hat{\theta}_n))^2$$

$$\text{ដែល } Bias(\hat{\theta}_n) = E(\hat{\theta}_n) - \theta$$

ឧទាហរណ៍ ៧. ចូរគណនាពាក្យក្នុងនិយមន័យទាំង ៤ ខាងលើចំពោះ θ_n ក្នុងបំណែងបែក Bernoulli ។

ការសន្មត ២. (derivative condition): មាន X_i អថេរចៃដន្យ i.i.d និង ដង់ស៊ីតេ $f_\theta(x)$ ។

- f មានដេរីវេលំដាប់ពីរធៀបនឹង θ
- $\int f_\theta(x) dx$ មានដេរីវេលំដាប់ពីរក្រោមសញ្ញាអាំងតេក្រាលធៀបនឹង θ

បទគន្លឹះ ១. : ឧបមាថា X (អថេរចៃដន្យតែមួយ) មានអនុគមន៍ដង់ស៊ីតេ $f_\theta(x)$ ។ ក្រោមការសន្មតទាំងពីរខាងលើយើងបាន៖

- $E\left(\frac{\partial \log(f_\theta(x))}{\partial \theta}\right) = 0$
- $E\left(\frac{\partial^2 \log(f_\theta(x))}{\partial \theta^2}\right) = -E\left[\left(\frac{\partial \log(f_\theta(x))}{\partial \theta}\right)^2\right]$

សម្រាយ

dfdsgsdgdfghgdfgsfd □

និយមន័យ ៥. Fisher Information ត្រូវបានគេអោយនិយមន័យដោយ

$$I(\theta) = -E\left(\frac{\partial^2 \log(f_\theta(x))}{\partial \theta^2}\right) = E\left[\left(\frac{\partial \log(f_\theta(x))}{\partial \theta}\right)^2\right] = V\left[\frac{\partial \log(f_\theta(x))}{\partial \theta}\right]$$

ឧទាហរណ៍ ៨. ចូរគណនា $I(\theta)$ នៃ $X \sim \text{Ber}(p)$ ។

ករណីទូទៅ: ឧបមាថា $X_1, X_2, \dots, X_n, i.i.d$ មានអនុគមន៍ដង់ស៊ីតេ $f_\theta(x)$ ។ នោះយើងបាន៖

- $E\left(\frac{\partial l}{\partial \theta}\right) = 0$
- $E\left(\frac{\partial^2 l}{\partial \theta^2}\right) = -E\left[\left(\frac{\partial l}{\partial \theta}\right)^2\right]$
- $V\left[\frac{\partial l}{\partial \theta}\right] = -E\left(\frac{\partial^2 l}{\partial \theta^2}\right) = E\left[\left(\frac{\partial l}{\partial \theta}\right)^2\right] = nI(\theta)$

ទ្រឹស្តីបទ ២. (Rao-Cramér Lower Bound): ឧបមាថា $X_1, X_2, \dots, X_n, i.i.d$ មានអនុគមន៍ដង់ស៊ីតេ $f_\theta(x)$ ។ ឧបមាថាយើងមានការសន្មតខាងលើ។ តាង $Y = u(X_1, X_2, \dots, X_n)$ ដែល $E(Y) = k(\theta)$ នោះយើងបាន៖

$$V(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}$$

សម្រាយ

fgfdgfd □

៣ ទ្រឹស្តីបទលីមីត (Limit Theorem)

៣.១ ភាពរួមបញ្ចូលនៃអថេរចៃដន្យ (Convergences of Sequence of Random Variables)

៣.២ ច្បាប់នៃតំលៃធំ (Law of Large Number:LLN)

៣.៣ ទ្រឹស្តីបទតំលៃកណ្តាល (Central Limit Theorem:CLT)

៤ ការប៉ាន់ស្មានជាចន្លោះ (Interval Estimation)

៤.១ ការប៉ាន់ស្មានជាចន្លោះចំពោះសមាមាត្រ (Interval Estimation for Proportion)

៤.២ ការប៉ាន់ស្មានជាចន្លោះចំពោះមធ្យម (Interval Estimation for Mean)

៤.៣ ការប៉ាន់ស្មានជាចន្លោះចំពោះភាពខុសគ្នា (Interval Estimation for Variance)